Tokenization in Natural Language Processing

2/2565: FRA501 Introduction to Natural Language Processing with Deep learning

Week 02

Paisit Khanarsa, Ph.D.

Institute of Field Robotics (FIBO), King Mongkut's University of Technology Thonburi

Outlines

- Why we do tokenization?
- Tokenization approaches
  - Dictionary-based
    - Longest matching
    - Maximal matching
  - Machine learning and deep learning-based
- Demo

Why we do tokenization?

- Text as a steam of characters

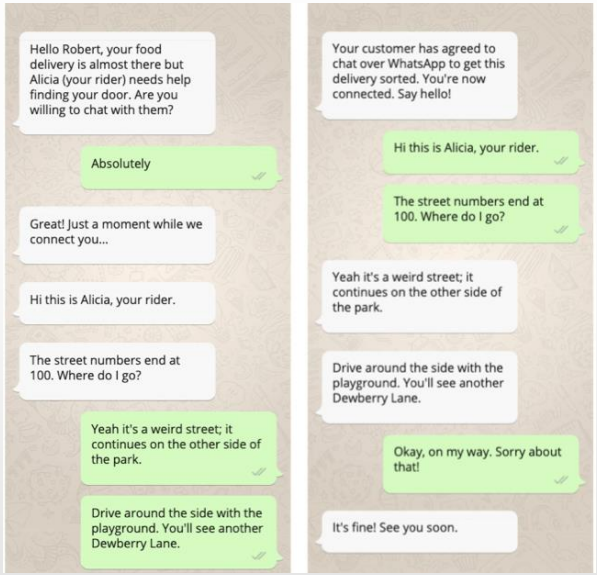

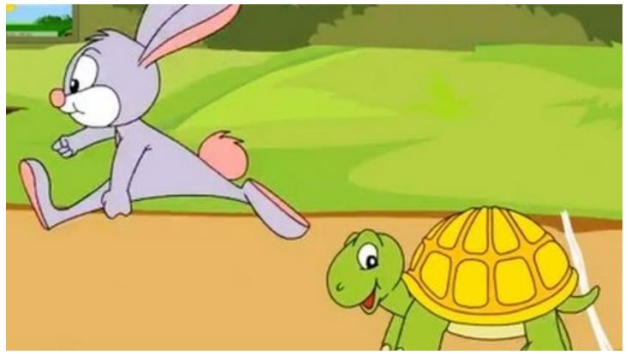

rajathathablog. the rabbit vs the tortoise

Rabbit and tortoise. Story continues.

"Once upon a time a Tortoise and a Rabbit had an

faster.

They decided to settle the argument with a race. T

and started off the race. The rabbit shot ahead an

time. Then seeing that he was far ahead of the tortoise, he thought he'd sit

under a tree for some time and relax before continuing the race. He sat

under the tree and soon fell asleep. The tortoise plodding on overtook him

and

soon finished the race, emerging as the undisputed champ. The rabbit woke

up and realized that he'd lost the race."

The moral of the story is that slow and steady wins the race. This is the version of the story that we've all grown up with.

But then recently, the story still continues:

- How to understand the meaning of texts
  - Break into words (assign meaning to words) ---> Word tokenization
  - Break into sentences (put word meaning back to sentence meaning)

Level of understand in NLP

Lexical Analysis: Text / Paragraphs, sentences, and words

Syntactic Analysis (Parsing): Grammar / Relationship between words

Semantic Analysis: Exact meaning of the sentence

Discourse Integration: Meaning of the sentences (based on the previous sentence, pronouns)

Pragmatic Analysis: Actual meaning based on the context and real-world knowledge

https://www.tutorialspoint.com/artificial_intelligence/artificial_intelligence_natural_language_processing.htm

Tokenization – Thai (cont.)

- Thai has no space between words
- Thai has no clear sentence boundaries

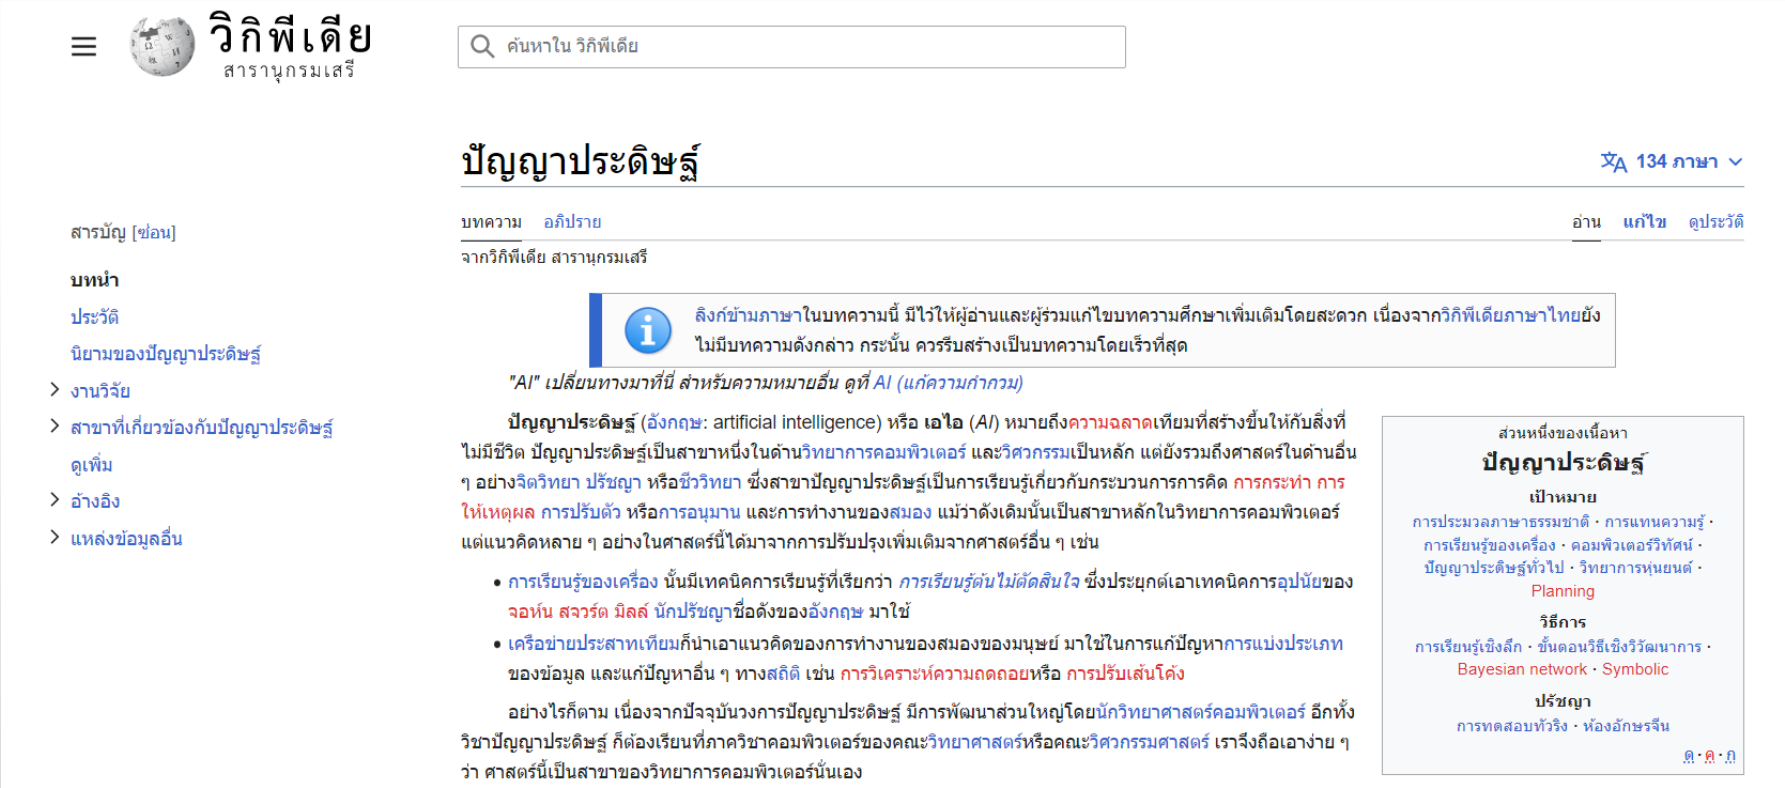

วิกิพีเดีย
สารานุกรมเสรี

ค้นหาใน วิกิพีเดีย

ปัญญาประดิษฐ์

134 ภาษา

บทความ อภิปราย อ่าน แก้ไข ดูประวัติ

จากวิกิพีเดีย สารานุกรมเสรี

สารบัญ [ซ่อน]

บทนำ
ประวัติ
นิยามของปัญญาประดิษฐ์
งานวิจัย
สาขาที่เกี่ยวข้องกับปัญญาประดิษฐ์
ดูเพิ่ม
อ้างอิง
แหล่งข้อมูลอื่น

ลิงก์ข้ามภาษาในบทความนี้ มีไว้ให้ผู้อ่านและผู้ร่วมแก้ไขบทความศึกษาเพิ่มเติมโดยสะดวก เนื่องจากวิกิพีเดียภาษาไทยยังไม่มีบทความดังกล่าว กระนั้น ควรรีบสร้างเป็นบทความโดยเร็วที่สุด

"AI" เปลี่ยนทางมาที่นี่ สำหรับความหมายอื่น ดูที่ AI (แก้ความกำกวม)

ปัญญาประดิษฐ์ (อังกฤษ: artificial intelligence) หรือ **เอไอ** (*AI*) หมายถึงความฉลาดเทียมที่สร้างขึ้นให้กับสิ่งที่ไม่มีชีวิต ปัญญาประดิษฐ์เป็นสาขาหนึ่งในด้านวิทยาการคอมพิวเตอร์ และวิศวกรรมเป็นหลัก แต่ยังรวมถึงศาสตร์ในด้านอื่น ๆ อย่างจิตวิทยา ปรัชญา หรือชีววิทยา ซึ่งสาขาปัญญาประดิษฐ์เป็นการเรียนรู้เกี่ยวกับกระบวนการการคิด การกระทำ การให้เหตุผล การปรับตัว หรือการอนุมาน และการทำงานของสมอง แม้ว่าดังเดิมนั้นเป็นสาขาหลักในวิทยาการคอมพิวเตอร์ แต่แนวคิดหลาย ๆ อย่างในศาสตร์นี้ได้มาจากการปรับปรุงเพิ่มเติมจากศาสตร์อื่น ๆ เช่น

- การเรียนรู้ของเครื่อง นั้นมีเทคนิคการเรียนรู้ที่เรียกว่า *การเรียนรู้ต้นไม่ตัดสินใจ* ซึ่งประยุกต์เอาเทคนิคการอุปนัยของ จอห์น สจวร์ต มิลล์ นักปรัชญาชื่อดังของอังกฤษ มาใช้
- เครือข่ายประสาทเทียมก็นำเอาแนวคิดของการทำงานของสมองของมนุษย์ มาใช้ในการแก้ปัญหาการแบ่งประเภทของข้อมูล และแก้ปัญหาอื่น ๆ ทางสถิติ เช่น การวิเคราะห์ความถดถอยหรือ การปรับเส้นโค้ง

อย่างไรก็ตาม เนื่องจากปัจจุบันวงการปัญญาประดิษฐ์ มีการพัฒนาส่วนใหญ่โดยนักวิทยาศาสตร์คอมพิวเตอร์ อีกทั้งวิชาปัญญาประดิษฐ์ ก็ต้องเรียนที่ภาควิชาคอมพิวเตอร์ของคณะวิทยาศาสตร์หรือคณะวิศวกรรมศาสตร์ เราจึงถือเอาง่าย ๆ ว่า ศาสตร์นี้เป็นสาขาของวิทยาการคอมพิวเตอร์นั่นเอง

ส่วนหนึ่งของเนื้อหา
ปัญญาประดิษฐ์
เป้าหมาย
การประมวลภาษาธรรมชาติ · การแทนความรู้ · การเรียนรู้ของเครื่อง · คอมพิวเตอร์วิทัศน์ · ปัญญาประดิษฐ์ทั่วไป · วิทยาการหุ่นยนต์ · Planning
วิธีการ
การเรียนรู้เชิงลึก · ขั้นตอนวิธีเชิงวิวัฒนาการ · Bayesian network · Symbolic
ปรัชญา
การทดสอบทัวริง · ห้องอักษรจีน
ดู · ค · ก

https://th.wikipedia.org/wiki/%E0%B8%9B%E0%B8%B1%E0%B8%8D%E0%B8%8D%E0%B8%B2%E0%B8%9B%E0%B8%A3%E0%B8%B0%E0%B8%94%E0%B8%B4%E0%B8%A9%E0%B8%90%E0%B9%8C

Tokenization – Thai (cont.)

- Social media texts

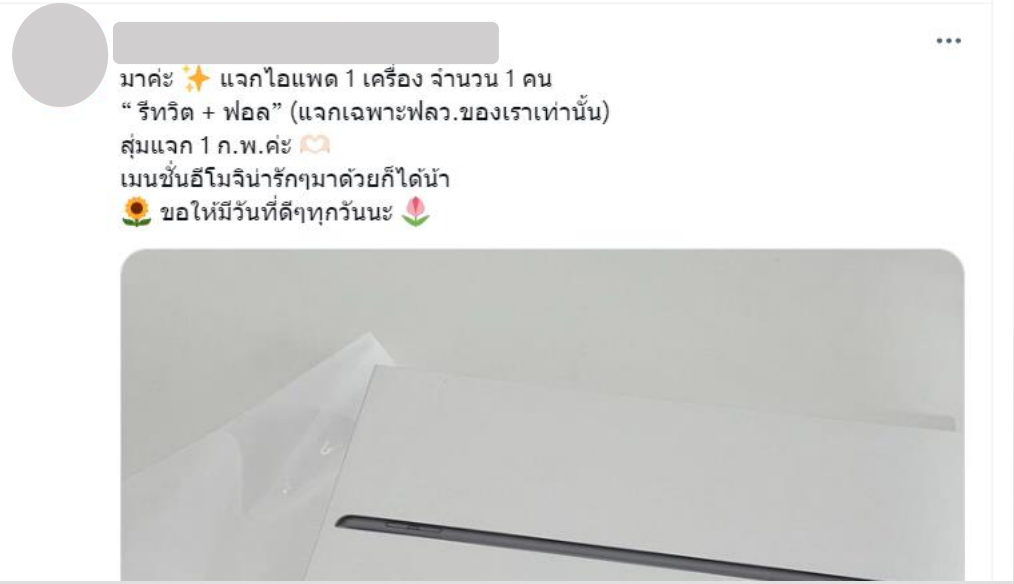

Tokenization – Thai (cont.)

- Many word boundaries depend on the context (meaning)

ตา กลม VS ตาก ลม

- Even amongst Thais the definition of word boundary is unclear
  - Needs a consensus when designing a corpus
  - Sometimes depends on the application

Tokenization - English

- Space is usually not enough
  - aren't
    - are + n't
    - aren't
    - arent
    - aren + t
    - are + not
  - San Francisco
    - San + Francisco
    - San Francisco

- Hyphens
  - The New York-based co-operation was fine-tuning forty-two K-9-like models

- Social media texts
  - @SentimentSymp: can't wait for the Nov 9 #Sentiment talks! YAAAAAAY!!! >:-D http://sentimentsymposium.com/.

Tokenization – English (cont.)

- Social media texts
  - @SentimentSymp: can't wait for the Nov 9 #Sentiment talks! YAAAAAAY!!! >:-D http://sentimentsymposium.com/.

Hand-crafted for tweets

```
@sentimentsymp
:
can't
wait
for
the
Nov_09
#sentiment
talks
!
YAAAY
!
!
!
>:-D
http://sentimentsymposium.com/
.
```

Standard tokenizer
(Stanford tokenizer)

```
@
SentimentSymp
:
ca
n't
wait
for
the
Nov
9
#
Sentiment
talks
!
YAAAAAAY
!
!
!
&gt;
;
:
-D
http
:
//sentimentsymposium.com/
.
```

Tokenization approaches

- Dictionary-based ---> Perform by scanning a string and match each sub string against words from **<u>dictionary</u>**.
  - Longest matching
  - Maximal matching
- Machine learning and deep learning-based ---> Change word to latent vector by training word features

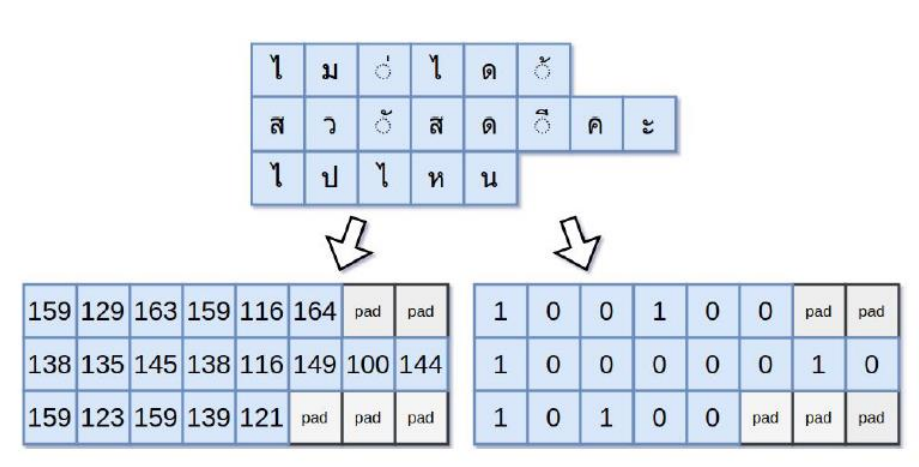

http://web.archive.org/web/20181005101442/https://sertiscorp.com/thai-word-segmentation-with-bi-directional_rnn/

Longest Matching

- Scan a sentence from left to right
- Keep finding a word from the starting point, until no word matched (longest), then move to the next point
- Backtrack if current segmentation leads to an un-segmentable chunk

Example	Steps
ป้ายกลับรถ	Star scanning with “ป” as the starting point
ป้ายกลับรถ	Keep scanning
ป้าย / กลับรถ	No more words start with “ป้าย”, move to the next point
....	....
ป้าย / กลับ / รถ	Finish

Maximal Matching

- Generate all possible segmentations
- Select the segmentations with **the fewest words**

ไปหามเหสี

Longest Matching -----> ไป | หาม | เห | สี 4 words

Maximal Matching -----> ไป | หา | มเหสี 3 words

Maximal Matching

- Generate all possible segmentations
- Select the segmentations with **the fewest words**

- Maximal matching can be done using dynamic programming.
- Let d(i,j) be the function which returns number of the fewest word possible with the last word starts with i^{th} character (row) and ends with j^{th} character (column). It can be defined as:

$$d(i,j) = \begin{cases} 1 & \text{if i=1 and c[1, j] is in the dictionary.} \\ 1 + min_{k=1\ldots i-1} d(k, i-1) & \text{if c[i..j] is in the dictionary.} \\ \infty, & \text{otherwise.} \end{cases}$$

when c[i..j] is a string of word in the sentence (assume it is started at index 1) and the base case is d(1,1) = 1.

Maximal Matching example

Input: ไปหามเหสี

Dict: ไ, ป, ห, า, ม, เ, ส, ี,ไป, หา, หาม, เห, สี, มเหสี

Each $d[i,j]$ stores number of the fewest words, with the latest word starting at i and ending at j

	ไ	ป	ห	า	ม	เ	ห	ส	ี
	1	2	3	4	5	6	7	8	9
1	1	1	∞	∞	∞	∞	∞	∞	∞
2		2	∞	∞	∞	∞	∞	∞	∞
3			2	2	2	∞	∞	∞	∞
4				3	∞	∞	∞	∞	∞
5					3	∞	∞	∞	3
6						3	3	∞	∞
7							4	∞	∞
8								4	4
9									5

Maximal Matching example

Input: ไปหามเหสี

Dict: ไ, ป, ห, า, ม, เ, ส, ี,ไป, หา, หาม, เห, สี, มเหสี

Each $d[i,j]$ stores number of the fewest words, with the latest word starting at i and ending at j

	ไ	ป	ห	า	ม	เ	ห	ส	ี
	1	2	3	4	5	6	7	8	9
1	1	1	∞	∞	∞	∞	∞	∞	∞
2		2	∞	∞	∞	∞	∞	∞	∞
3			2	2	2	∞	∞	∞	∞
4				3	∞	∞	∞	∞	∞
5					3	∞	∞	∞	3
6						3	3	∞	∞
7							4	∞	∞
8								4	4
9									5

[ไ]

[ไป]

Maximal Matching example

Input: ไปหามเหสี

Dict: ไ, ป, ห, า, ม, เ, ส, ี,ไป, หา, หาม, เห, สี, มเหสี

Each $d[i,j]$ stores number of the fewest words, with the latest word starting at i and ending at j

	ไ	ป	ห	า	ม	เ	ห	ส	ี
	1	2	3	4	5	6	7	8	9
1	1	1	∞	∞	∞	∞	∞	∞	∞
2		2	∞	∞	∞	∞	∞	∞	∞
3			2	2	2	∞	∞	∞	∞
4				3	∞	∞	∞	∞	∞
5					3	∞	∞	∞	3
6						3	3	∞	∞
7							4	∞	∞
8								4	4
9									5

[ไ]

[ไป]

[ไ, ป]

Maximal Matching example

Input: ไปหามเหสี

Dict: ไ, ป, ห, า, ม, เ, ส, ี,ไป, หา, หาม, เห, สี, มเหสี

Each $d[i,j]$ stores number of the fewest words, with the latest word starting at i and ending at j

	ไ	ป	ห	า	ม	เ	ห	ส	ี
	1	2	3	4	5	6	7	8	9
1	1	1	∞	∞	∞	∞	∞	∞	∞
2		2	∞	∞	∞	∞	∞	∞	∞
3			2	2	2	∞	∞	∞	∞
4				3	∞	∞	∞	∞	∞
5					3	∞	∞	∞	3
6						3	3	∞	∞
7							4	∞	∞
8								4	4
9									5

[ไ]

[ไป]

[ไ, ป]

[ไป, ห]

[ไป, หา]

Maximal Matching example

Input: ไปหามเหสี

Dict: ไ, ป, ห, า, ม, เ, ส, ี,ไป, หา, หาม, เห, สี, มเหสี

Each $d[i,j]$ stores number of the fewest words, with the latest word starting at i and ending at j

	ไ	ป	ห	า	ม	เ	ห	ส	ี
	1	2	3	4	5	6	7	8	9
1	1	1	∞	∞	∞	∞	∞	∞	∞
2		2	∞	∞	∞	∞	∞	∞	∞
3			2	2	2	∞	∞	∞	∞
4				3	∞	∞	∞	∞	∞
5					3	∞	∞	∞	3
6						3	3	∞	∞
7							4	∞	∞
8								4	4
9									5

[ไ]

[ไป]

[ไ, ป]

[ไป, ห]

[ไป, หา]

[ไป, หา, มเหสี]

Maximal Matching example

Input: ไปหามเหสี

Dict: ไ, ป, ห, า, ม, เ, ส, ี,ไป, หา, หาม, เห, สี, มเหสี

Each $d[i,j]$ stores number of the fewest words, with the latest word starting at i and ending at j

	ไ	ป	ห	า	ม	เ	ห	ส	ี
	1	2	3	4	5	6	7	8	9
1	1	1	∞	∞	∞	∞	∞	∞	∞
2		2	∞	∞	∞	∞	∞	∞	∞
3			2	2	2	∞	∞	∞	∞
4				3	∞	∞	∞	∞	∞
5					3	∞	∞	∞	3
6						3	3	∞	∞
7							4	∞	∞
8								4	4
9									5

[ไ]

[ไป]

[ไ, ป]

[ไป, ห]

[ไป, หา]

[ไป, หา, มเหสี]

[ไป, หาม, เห]

Maximal Matching example

Input: ไปหามเหสี

Dict: ไ, ป, ห, า, ม, เ, ส, ี,ไป, หา, หาม, เห, สี, มเหสี

Each $d[i,j]$ stores number of the fewest words, with the latest word starting at i and ending at j

	ไ	ป	ห	า	ม	เ	ห	ส	ี
	1	2	3	4	5	6	7	8	9
1	1	1	∞	∞	∞	∞	∞	∞	∞
2		2	∞	∞	∞	∞	∞	∞	∞
3			2	2	2	∞	∞	∞	∞
4				3	∞	∞	∞	∞	∞
5					3	∞	∞	∞	3
6						3	3	∞	∞
7							4	∞	∞
8								4	4
9									5

[ไ]

[ไป]

[ไ, ป]

[ไป, ห]

[ไป, หา]

Backtracking

[ไป, หา, มเหสี]

[ไป, หาม, เห]

Machine learning and deep learning-based

- Can represent the meaning of characters, words, sentences, etc. by training data.
- Thai-Tokenization

TABLE II
RESULTS OF THE SIX BEST TEAMS

Type of participants	F-Measure (%)	Time (mm:ss)
Non-Students[a]	97.94937	00:47
Non-Students	97.84097	02:46
Non-Students	97.18822	00:26
Bachelor Students[b]	95.78162	01:08
Master Students	95.56670	12:14
PhD+Master Students	92.02067	02:28

[a]Best of the BEST 2009 Award Winner
[b]BEST Student 2009 Award Winner

BEST 2009 : Thai word segmentation software contest
https://ieeexplore.ieee.org/document/5340941

DeepCut (Thai-Tokenization)

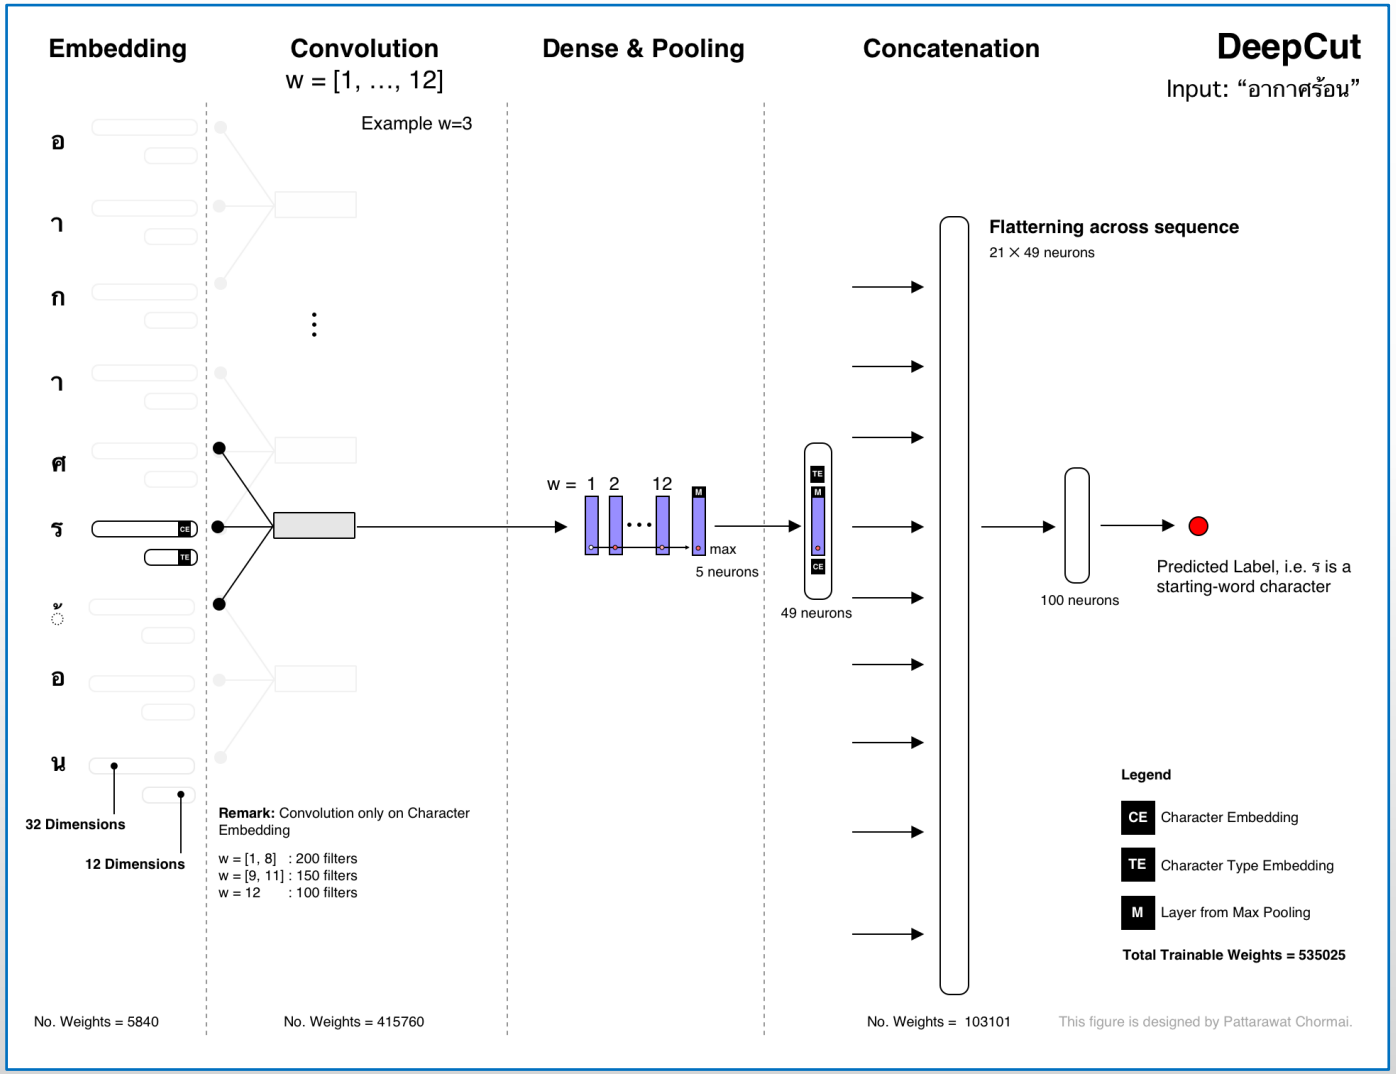

https://github.com/rkcosmos/deepcut

SERTIS (Thai-Tokenization)

Thai word segmentation with bi-directional RNN

https://www.sertiscorp.com/th/november-20-2017

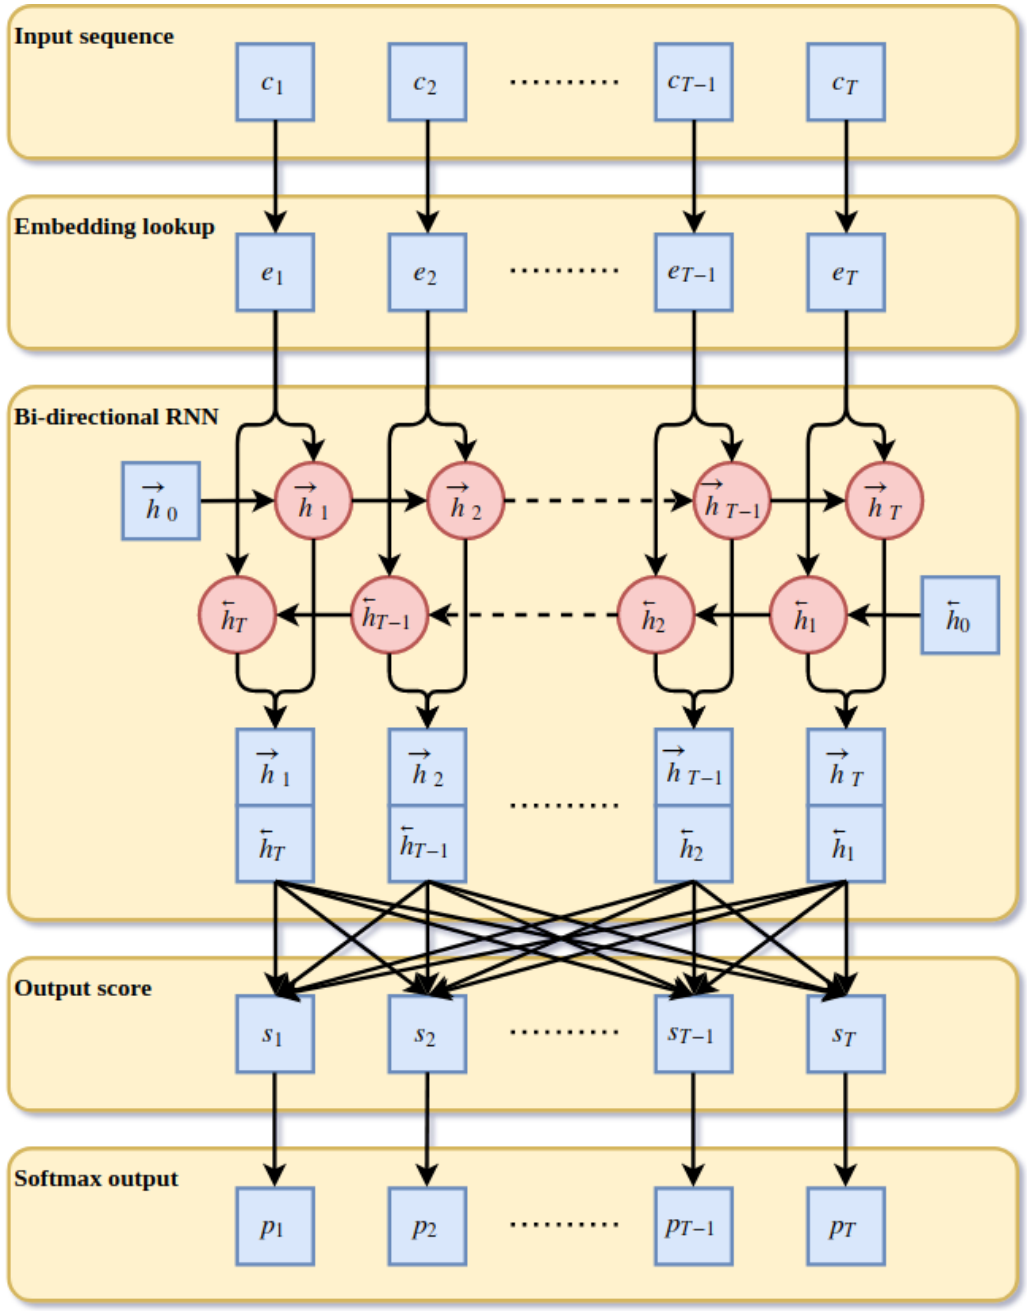

$$e_t = W_c c_t$$

$$z_t = \text{sigmoid}(W_z e_t + U_z h_{t-1} + b_z)$$

$$r_t = \text{sigmoid}(W_r e_t + U_r h_{t-1} + b_r)$$

$$h_t = z_t \odot h_{t-1} + (1 - z_t) \odot \tanh(W_h e_t + U_h (r_t \odot h_{t-1}) + b_h)$$

$$H_t = [\vec{h}_t, \overleftarrow{h}_{T-t+1}]$$

$$s_t = H_t W_s + b_s^T$$

$$p_t = \frac{\exp(s_t)}{\exp(s_{t1}) + \exp(s_{t2})}$$

AttaCut (Thai-Tokenization)

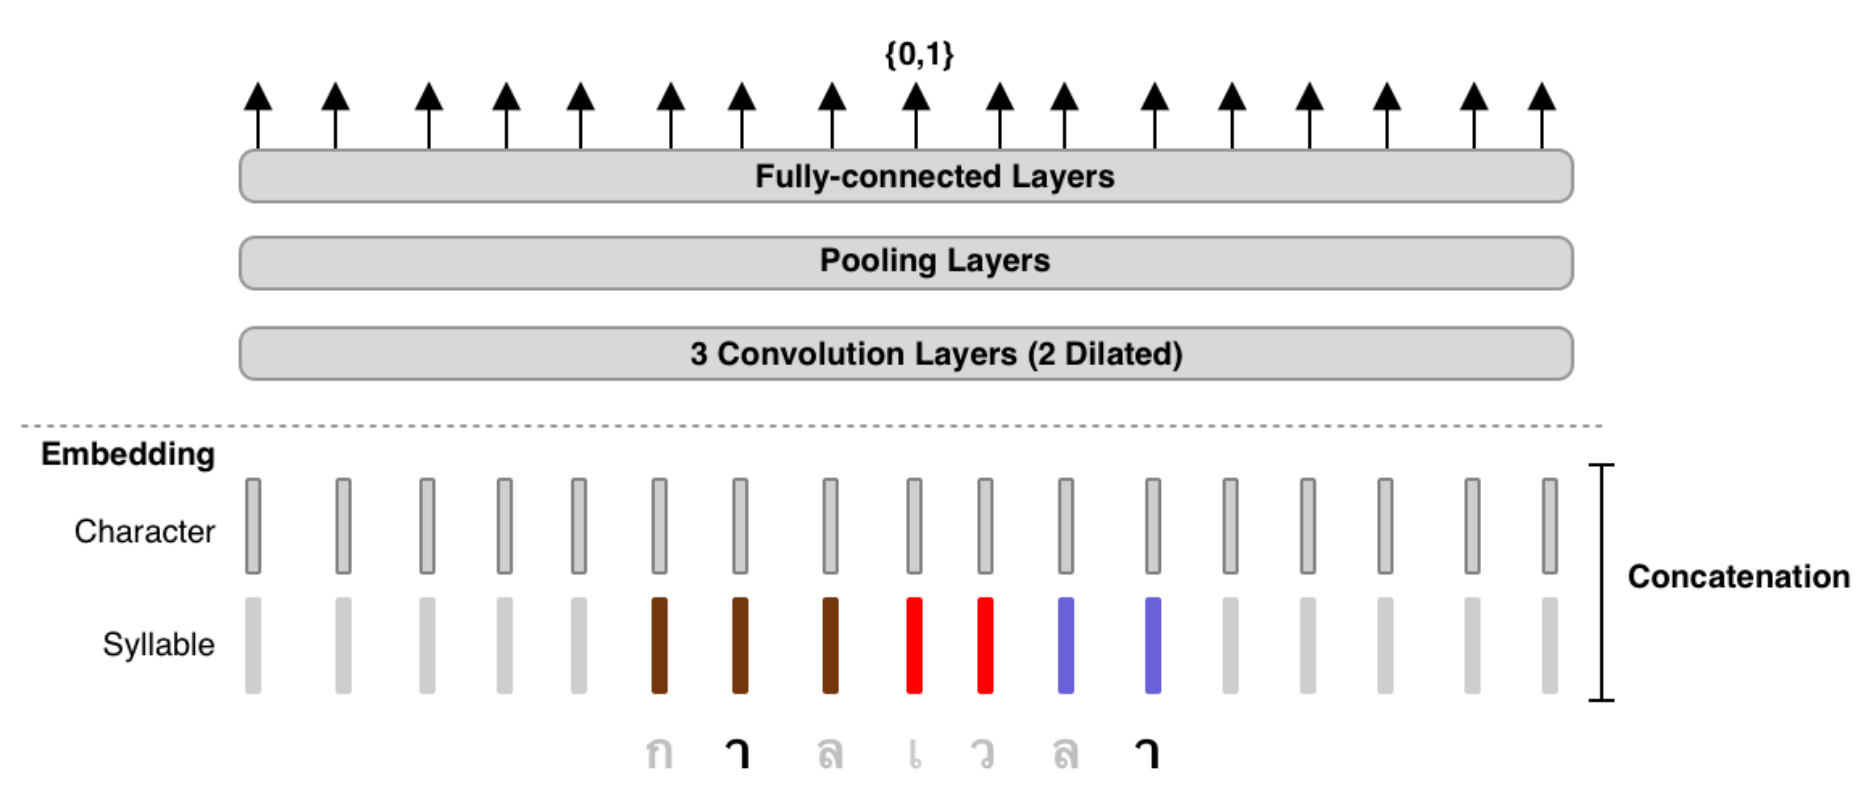

TL;DR: 3-Layer Dilated CNN on syllable and character features. It's **6x faster** than DeepCut (SOTA) while its WL-f1 on BEST is **91%**, only 2% lower.

https://github.com/PyThaiNLP/attacut

Thai-Tokenization Quality

		Others			Ours	
Last Updated: 29/08/2019		**PyThaiNLP newmm**	**Sertis Bi-GRU**	**DeepCut**	**AttaCut-C**	**AttaCut-SC**
BEST Validation Set						
Character-Level	precision	0.94±0.11	0.95±0.10	0.99±0.05	0.97±0.07	0.98±0.05
	recall	0.83±0.09	0.99±0.02	0.99±0.03	0.98±0.04	0.99±0.03
	f1	0.88±0.08	0.97±0.07	**0.99±0.04**	0.98±0.05	0.99±0.04
Word-Level	precision	0.73±0.16	0.91±0.14	0.97±0.07	0.94±0.10	0.96±0.08
	recall	0.65±0.16	0.94±0.10	0.97±0.07	0.94±0.09	0.97±0.08
	f1	0.68±0.15	0.93±0.12	**0.97±0.07**	0.94±0.10	**0.97±0.08**
BEST Test Set						
Character-Level	precision	0.91±0.15	0.92±0.11	0.96±0.08	0.94±0.10	0.95±0.09
	recall	0.85±0.09	0.98±0.04	0.98±0.04	0.98±0.04	0.98±0.04
	f1	0.86±0.11	0.95±0.08	**0.97±0.06**	0.96±0.07	0.96±0.07
Word-Level	precision	0.70±0.19	0.85±0.18	0.92±0.14	0.88±0.17	0.91±0.15
	recall	0.64±0.18	0.90±0.14	0.93±0.12	0.91±0.14	0.92±0.13
	f1	0.67±0.19	0.87±0.16	**0.93±0.13**	0.89±0.16	0.91±0.14

Thai-Tokenization Quality

		Others			Ours	
Last Updated: 29/08/2019		PyThaiNLP newmm	Sertis Bi-GRU	DeepCut	AttaCut-C	AttaCut-SC
BEST						
C						±0.05
						±0.03
						±0.04
						±0.08
						±0.08
						±0.08
C						±0.09
						±0.04
						±0.07
						±0.15
Word-Level	recall					±0.13
	f1	0.67±0.19	0.87±0.16	**0.93±0.13**	0.89±0.16	0.91±0.14

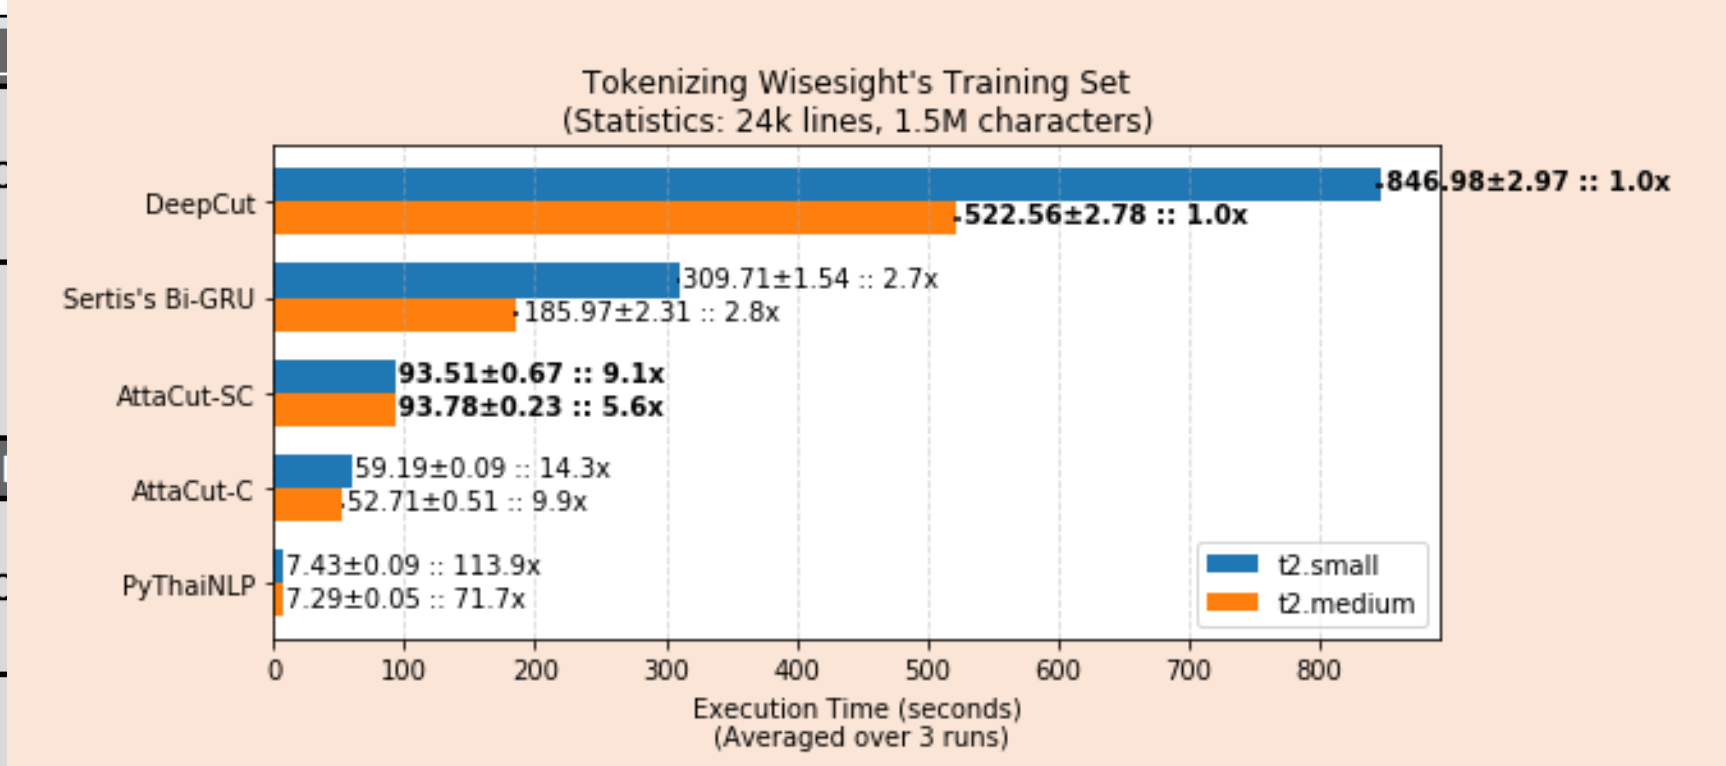

Word of caution

- A tokenizer trained on social text might not be able to cut simple words like

	WS160	TNHC
Deepcut	93.8	93.5
Attacut	93.5	80.8

https://www.aclweb.org/anthology/2020.emnlp-main.315/

- Examples
  - มะม่วง มะละกอ ---> มะ | ม่วง | มะ |ละ |กอ
  - หมูกรอบ ---> หมู | กรอบ
  - ข้าวผัดคะน้าหมูกรอบหนึ่งจาน ---> ข้าว | ผัด | คะน้า | หมูก| รอบ| หนึ่ง | จาน

- Effect downstream task

Word of caution

- A tokenizer trained on social text might not be able to cut simple words like

	WS160	TNHC
Deepcut	93.8	93.5
Attacut	93.5	80.8

https://www.aclweb.org/anthology/2020.emnlp-main.315/

Might need Dictionary-based !

- Examples
  - มะม่วง มะละกอ ---> มะ | ม่วง | มะ |ละ |กอ
  - หมูกรอบ ---> หมู | กรอบ
  - ข้าวผัดคะน้าหมูกรอบหนึ่งจาน ---> ข้าว | ผัด | คะน้า | หมูก| รอบ| หนึ่ง | จาน

- Effect downstream task

NLP tools

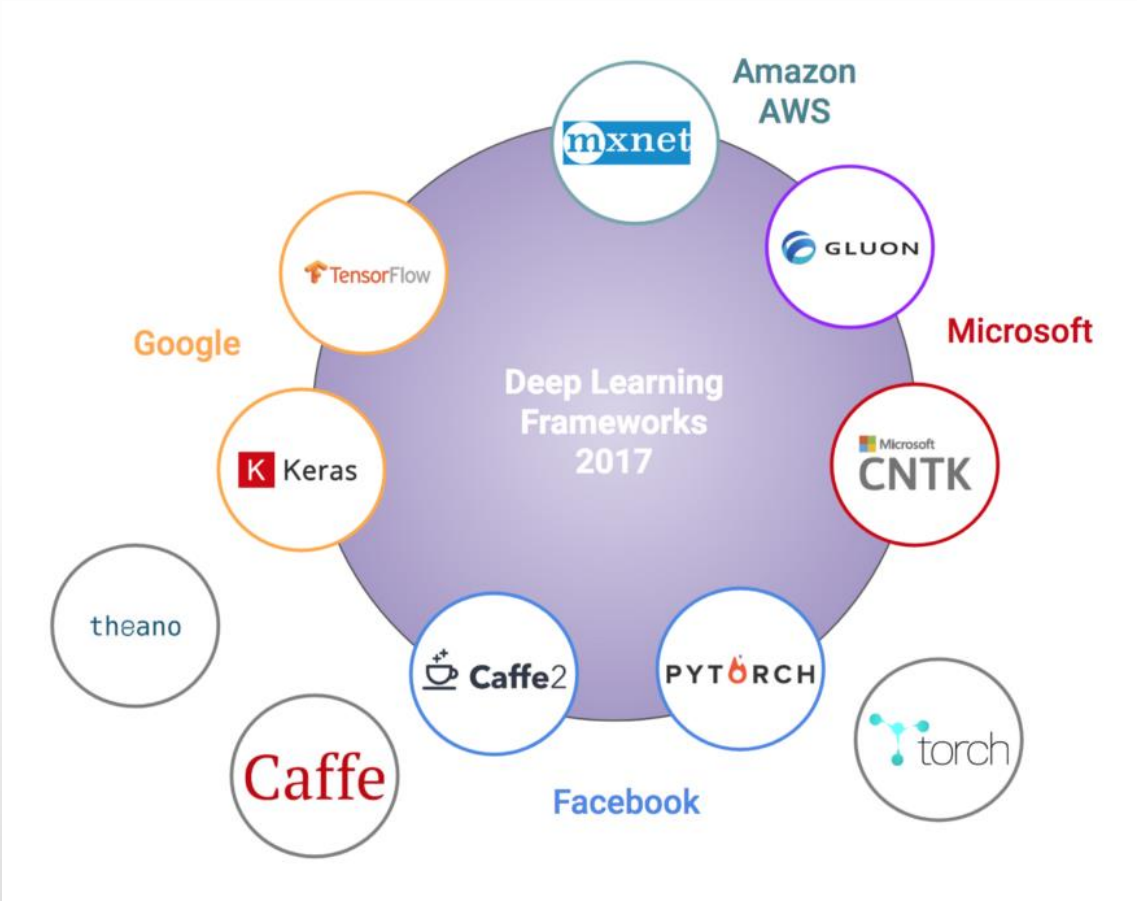

https://towardsdatascience.com/battle-of-the-deep-learning-frameworks-part-i-cff0e3841750

NLP Libraries

https://www.nltk.org/

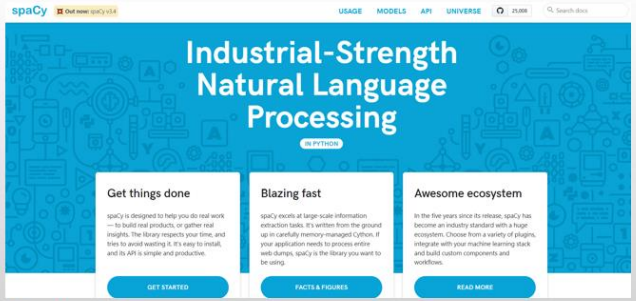

https://spacy.io/

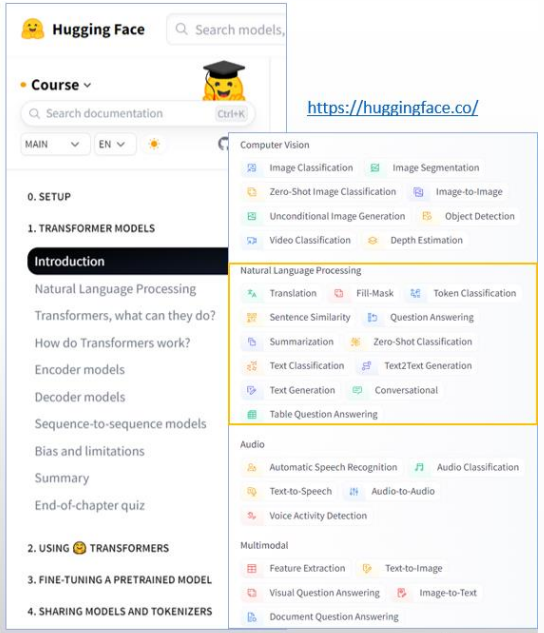

https://huggingface.co/

NLP Library for Thai

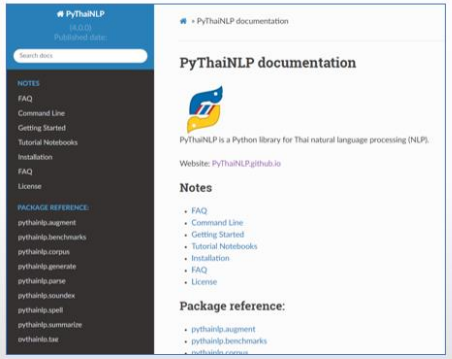

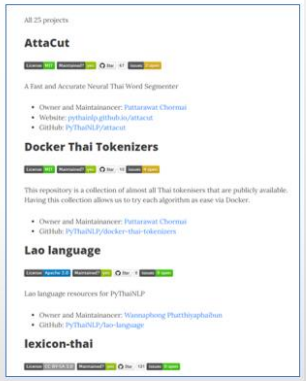

https://pythainlp.github.io/
https://pythainlp.github.io/docs/2.0/index.html

Demo: Word tokenization in Thai

https://drive.google.com/file/d/1oes0gZeddFbbsV4ymgDv4WyFDzreVqY9/view?usp=share_link